

BAB 1

PROBLEM DISCOVERY & PENDAHULUAN

1.1 Latar Belakang Masalah

Perkembangan teknologi digital telah mengubah cara masyarakat, khususnya generasi muda dalam melakukan transaksi keuangan. Besarnya pergeseran ini tercermin dari laporan BI 2025 yang menyatakan, nilai transaksi uang elektronik pada Februari 2025 mencapai Rp2.503,96 triliun atau tumbuh 34,62% dibandingkan tahun sebelumnya (Goodstats.id, 2025). Kehadiran berbagai layanan seperti *e-wallet*, *mobile banking*, dan *paylater* memberikan kemudahan dalam bertransaksi kapan saja dan di mana saja berpotensi memicu perilaku konsumtif, khususnya pada Generasi Z. Karakteristik Generasi Z yang menyukai kepraktisan sangat selaras dengan metode pembayaran nontunai ini, namun di sisi lain mereka rentan terdorong membeli barang yang diinginkan tanpa pertimbangan matang, sering kali hanya mengikuti tren (Wardhana, 2020).

Data Badan Pusat Statistik mencatat bahwa rata-rata pengeluaran bulanan masyarakat meningkat dari Rp1,26 juta pada 2021 menjadi Rp1,50 juta pada 2024 (BPS, 2024). Lebih jauh, Wibowo et al. (2024) mengungkapkan tingginya konsumsi pada era *cashless society* dapat memicu eksploitasi sumber daya berlebihan, degradasi lingkungan, dan ketidakseimbangan ekonomi. Dampak tersebut bersinggungan langsung dengan SDGs poin ke-12 tentang Konsumsi dan Produksi yang Bertanggung Jawab. Kesulitan dalam mencapai tujuan ini salah satunya disebabkan oleh rendahnya literasi keuangan masyarakat Indonesia (Soenjoto & Mahmudah, 2023). Berdasarkan Survei Nasional Literasi dan Inklusi Keuangan (SNLIK) 2024 yang dilakukan OJK bersama BPS, indeks literasi keuangan Indonesia hanya sebesar 65,43%, sementara indeks inklusi keuangan telah mencapai 75,02%. Kesenjangan antara literasi dan inklusi keuangan ini mengakibatkan minimnya kemampuan mengelola keuangan, termasuk membedakan antara

kebutuhan dan keinginan.

Permasalahan semakin kompleks karena sebagian besar aplikasi pengelolaan keuangan yang tersedia memiliki proses pencatatan transaksi yang dianggap rumit, memakan waktu, dan membutuhkan konsistensi tinggi. Selain itu, prosesnya hanya berfokus pada fungsi pencatatan transaksi, tanpa menyediakan analisis maupun wawasan yang membantu pengguna memahami pola pengeluaran secara menyeluruh. Akibatnya, pengguna kehilangan informasi penting mengenai kondisi keuangan mereka dan berpotensi mengambil keputusan finansial yang kurang tepat. Oleh karena itu, inovasi dalam pengelolaan keuangan menjadi kebutuhan mendesak agar pengguna mampu memahami pola pengeluarannya dan membuat keputusan finansial yang lebih bijak.

1.2 Solusi Utama

Sebagai solusi permasalahan tersebut, tim mengembangkan **SpendiGo**, sebuah platform pengelolaan keuangan berbasis web yang membantu pengguna mencatat, memantau, dan memahami kondisi keuangan mereka secara lebih mudah. Sistem ini dirancang dengan antarmuka yang intuitif sehingga dapat mengurangi hambatan pengguna dalam melakukan pencatatan transaksi secara konsisten. Data transaksi yang dikumpulkan kemudian diolah dan disajikan dalam bentuk dashboard interaktif, analisis pengeluaran, serta indikator kesehatan keuangan (*Financial Health Score*).

Sebagai nilai tambah, **SpendiGo** mengintegrasikan teknologi *Artificial Intelligence* (AI) menggunakan algoritma *Long Short-Term Memory* (LSTM) untuk memprediksi pengeluaran berdasarkan data historis pengguna. Selain itu, platform dilengkapi fitur *AI Financial Assistant* dan *What-If Simulator* yang membantu pengguna memperoleh insight keuangan serta mensimulasikan berbagai keputusan finansial. Keunggulan **SpendiGo** terletak pada

kemampuannya menggabungkan pencatatan keuangan, visualisasi data, dan prediksi berbasis AI dalam satu platform. Dengan demikian, pengguna tidak hanya mencatat transaksi, tetapi juga memperoleh informasi dan rekomendasi yang mendukung pengambilan keputusan keuangan yang lebih baik.

1.3 Pertanyaan Bisnis (Business Questions)

1. Bagaimana merancang sistem pencatatan keuangan yang mudah digunakan sehingga pengguna mau konsisten mencatat transaksi,
2. Bagaimana menyajikan data keuangan dalam bentuk yang sederhana namun informatif, dan
3. Bagaimana analisis data sederhana dapat memberikan insight yang relevan bagi pengguna.

BAB 2

DATA WRANGLING & PERSIAPAN DATA

2.1 Data Gathering (Pengumpulan Data)

Dataset yang digunakan dalam proyek ini merupakan data sintetis (synthetic dataset) yang dibuat secara mandiri menggunakan Python pada Google Colab. Penggunaan data sintetis dipilih karena keterbatasan akses terhadap data transaksi keuangan pribadi yang bersifat sensitif dan tidak mudah diperoleh secara publik. Proses penyusunan dataset diawali dengan studi pendahuluan mengenai perilaku keuangan Generasi Z di Indonesia melalui berbagai sumber, seperti artikel, berita, laporan, dan referensi terkait pengelolaan keuangan. Informasi yang dikumpulkan meliputi pola pendapatan, kebiasaan pengeluaran, penggunaan layanan keuangan digital, serta kategori transaksi yang umum dilakukan oleh Generasi Z.

Berdasarkan hasil studi tersebut, disusun sejumlah aturan dan skenario yang merepresentasikan kondisi nyata di lapangan. Selanjutnya, data sintetis dihasilkan dengan mempertimbangkan berbagai karakteristik transaksi keuangan, seperti pemasukan, pengeluaran, saldo, frekuensi transaksi, dan kategori pengeluaran. Dataset yang dihasilkan kemudian digunakan sebagai dasar dalam proses analisis data dan pengembangan model *Machine Learning*.

2.2 Data Assessing (Penilaian Kualitas Data)

Pemeriksaan awal dilakukan terhadap dataset transaksi keuangan yang digunakan dalam penelitian ini. Dataset terdiri dari 136.234 baris data yang merepresentasikan transaksi keuangan dari 100 pengguna dengan berbagai karakteristik finansial. Pada tahap awal, dataset memiliki 9 atribut utama, yaitu *User_ID*, *User_Type*, *Date*, *Category*, *Amount*, *Type*, *Year*, *Month*, dan *Day*. Hasil pemeriksaan menunjukkan bahwa tidak terdapat nilai yang hilang (*missing values*) pada seluruh atribut. Selain itu, tipe data pada setiap

kolom telah sesuai dengan kebutuhan analisis, di mana atribut tanggal bertipe *datetime*, atribut nominal transaksi bertipe numerik, dan atribut lainnya bertipe kategorikal. Pemeriksaan juga menunjukkan bahwa dataset tidak mengandung data duplikat yang dapat memengaruhi hasil analisis. Pada atribut numerik, khususnya kolom *Amount*, ditemukan beberapa transaksi dengan nominal yang lebih tinggi dibandingkan transaksi lainnya. Namun, nilai tersebut masih dianggap wajar karena merepresentasikan transaksi tertentu seperti penerimaan gaji, bonus, atau pengeluaran dalam jumlah besar.

2.3 Data Cleaning (Pembersihan Data)

Berdasarkan hasil pemeriksaan kualitas data, dilakukan proses validasi untuk memastikan dataset siap digunakan pada tahap analisis dan pemodelan. Proses yang dilakukan meliputi pengecekan nilai hilang (*missing values*), pengecekan data duplikat, serta verifikasi tipe data pada setiap atribut. Kolom *Date* dipastikan menggunakan format *datetime* agar dapat digunakan dalam analisis berbasis waktu (*time series*). Selanjutnya dilakukan validasi terhadap atribut numerik, khususnya pada kolom *Amount*, untuk memastikan tidak terdapat nilai yang tidak logis.

Karena tidak ditemukan nilai hilang maupun data duplikat, tidak diperlukan proses imputasi atau penghapusan data. Selain itu, nilai transaksi yang teridentifikasi sebagai *outlier* tetap dipertahankan karena masih merepresentasikan kondisi transaksi yang realistis dan diperlukan untuk menjaga keberagaman pola data yang akan dipelajari oleh model *Machine Learning*.

2.4 Data Dictionary (Kamus Data)

Sajikan informasi metadata mengenai dataset yang telah bersih menggunakan tabel di bawah ini.

Nama Fitur / Kolom	Tipe Data	Deskripsi Keterangan
User_ID	String	Identitas unik setiap pengguna.
Employment_Status	String	Status pekerjaan pengguna, seperti belum bekerja, part-time, atau full-time.
User_Type	String	Karakteristik finansial pengguna, seperti hemat, normal, boros, hustler, dan anak kos.
Date	Datetime	Tanggal transaksi dilakukan.
Category	String	Kategori transaksi, seperti makan, transportasi, hiburan, belanja online, dan lainnya.
Amount	Integer	Nominal transaksi yang dilakukan pengguna.
Type	String	Jenis transaksi, yaitu pemasukan (<i>Income</i>) atau pengeluaran (<i>Expense</i>).

Nama Fitur / Kolom	Tipe Data	Deskripsi Keterangan
Balance	Integer	Saldo pengguna setelah transaksi dilakukan.
Year	Integer	Tahun transaksi.
Month	Integer	Bulan transaksi.
Day	Integer	Tanggal dalam bulan transaksi.
Weekday	String	Nama hari pada saat transaksi dilakukan.
day_of_week	Integer	Representasi numerik hari dalam satu minggu (0–6).
is_weekday	Integer	Penanda apakah transaksi dilakukan pada hari kerja (1) atau tidak (0).
is_ramadan	Integer	Penanda apakah transaksi terjadi pada periode Ramadan (1) atau tidak (0).
is_harbolnas	Integer	Penanda apakah transaksi terjadi pada periode Hari Belanja Online Nasional (1) atau

Nama Fitur / Kolom	Tipe Data	Deskripsi Keterangan
		tidak (0).
amount_log	Float	Hasil transformasi logaritmik dari nilai transaksi untuk mengurangi skewness data.
is_income	Integer	Penanda transaksi pemasukan (1) atau bukan (0).


BAB 3

EXPLORATORY DATA ANALYSIS (EDA) & EXPLANATORY ANALYSIS

3.1 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) dilakukan untuk memahami karakteristik data transaksi keuangan pengguna, mengidentifikasi pola pengeluaran, serta mengetahui hubungan antar variabel sebelum dilakukan proses pemodelan Machine Learning.


3.1.1 Distribusi Pengeluaran Berdasarkan User Type



Gambar 3.1 Distribusi pengeluaran per *user type*

Dilihat dari distribusi pengeluaran pada masing-masing tipe *user*, hasil analisis menunjukkan bahwa *user* dengan tipe boros memiliki rata-rata pengeluaran tertinggi yaitu sebesar Rp. 41.860, diikuti oleh anak kos sebesar Rp. 35.847, lalu oleh *user* dengan pengeluaran normal sebesar Rp. 20.784 dan anak *hustler* sebesar Rp. 17.530. Sebaliknya, *user* dengan tipe hustler memiliki rata-rata pengeluaran terendah sebesar Rp. 14.971.. Temuan ini menunjukkan bahwa karakteristik pengguna memengaruhi pola pengeluaran yang dilakukan.


3.1.2 Tren Total Pengeluaran Bulanan



Gambar 3.2 Tren Total Pengeluaran Bulanan

Berdasarkan Gambar 3.2, total pengeluaran mengalami fluktuasi sepanjang periode pengamatan. Terlihat adanya peningkatan pengeluaran pada bulan-bulan tertentu, terutama pada periode Ramadan dan Harbolnas. Pola ini mengindikasikan adanya faktor musiman (*seasonality*) yang memengaruhi perilaku konsumsi pengguna. Temuan ini menjadi dasar penggunaan model LSTM yang dirancang untuk mempelajari pola temporal pada data deret waktu.

3.1.3 Analisis Korelasi Antar Fitur




Gambar 3.3 Heatmap Korelasi Fitur Numerik

Berdasarkan heatmap korelasi, variabel *is_income* memiliki korelasi positif terbesar terhadap variabel *Amount* dengan nilai korelasi sebesar 0,596 dan variabel *amount_log* memiliki korelasi sebesar 0,497 terhadap *Amount*. Sementara itu, variabel waktu seperti *Month*, *is_weekday*, *is_ramadan*, dan *is_harbolnas* menunjukkan korelasi yang relatif rendah secara individual. Hal ini mengindikasikan bahwa nominal transaksi lebih dipengaruhi oleh jenis transaksi dibandingkan faktor waktu secara langsung. Secara keseluruhan, hasil EDA menunjukkan bahwa pola pengeluaran dipengaruhi oleh karakteristik pengguna, jenis transaksi, dan faktor musiman tertentu. Temuan ini menjadi dasar dalam proses pengembangan fitur dan pembangunan model prediksi pengeluaran pada tahap selanjutnya.

3.2 Explanatory Analysis & Visualisasi Data

Pada subbab ini disajikan *explanatory analysis* dan visualisasi yang dilengkapi intepretasi dan telah difinalisasi untuk menjawab **Pertanyaan Bisnis** pada Bab 1.


3.2.1 Perbandingan Total *Income* dan *Expense*



Gambar 3.4 Perbandingan Total *Income* dan *Expense*

Diagram batang ini membandingkan total akumulasi pemasukan (*Income*) dan pengeluaran (*Expense*) dari 100 pengguna selama 2 tahun. Sumbu Y menampilkan nilai dalam satuan juta Rupiah. Dari visualisasi ini terlihat bahwa total income secara keseluruhan lebih besar dibandingkan total expense, yang menandakan bahwa secara kolektif pengguna masih dalam kondisi surplus. Namun ini adalah data agregat dari seluruh user yang tercampur, sehingga tidak mencerminkan kondisi keuangan per individu. Grafik ini menjawab **Pertanyaan Bisnis 2** dengan memberikan gambaran makro kondisi keuangan komunitas Gen-Z dalam dataset.

3.2.2 Total Pengeluaran per Kategori




Gambar 3.5 Total Pengeluaran per Kategori

Diagram batang di atas menampilkan urutan kategori pengeluaran (makan, transport, belanja online, dll.) berdasarkan total nominal Rupiah. Hasilnya menunjukkan bahwa kategori makan mendominasi pengeluaran, hal ini sangat wajar di kalangan mahasiswa Gen-Z. Insight ini memiliki

implikasi langsung terhadap desain produk, yakni untuk memprioritaskan fitur *budget alert* pada kategori makan sebagai kategori dengan risiko overbudget tertinggi. Hal ini membantu menjawab **Pertanyaan Bisnis 2** dengan menyajikan data sederhana namun langsung dapat diinterpretasi oleh pengguna.

3.2.3 Tren Total Pengeluaran Bulanan



Gambar 3.6 Tren Total Pengeluaran Bulanan

Grafik garis ini menampilkan total pengeluaran bulanan seluruh pengguna sepanjang rentang periode data (2 tahun). Terdapat pola fluktuasi yang terlihat jelas, di mana lonjakan pengeluaran terjadi pada bulan Maret–April (periode Ramadan) serta bulan November–Desember (periode Harbolnas 11/11 dan 12/12). Tren ini menjadi landasan empiris bagi model LSTM untuk belajar pola temporal pengeluaran. Hal ini menjawab **Pertanyaan Bisnis 2** sekaligus memberikan konteks musiman bagi pengguna.

3.2.4 Pola Harbolnas 11 November dan 12 Desember

```
=== HARBOLNAS 11.11 ===
Category
makan            122
transport         121
jajan_snack       59
kopi_cafe         35
online_shopping   31
game_topup        6
freelance         5
skincare_beauty   4
konser_event      2
fashion_outfit    2
paylater          1
kado_hadiah       1
Name: count, dtype: int64

=== HARBOLNAS 12.12 ===
Category
makan            132
transport         129
jajan_snack       58
online_shopping   38
kopi_cafe         36
skincare_beauty   4
fashion_outfit    3
game_topup        3
freelance         2
Name: count, dtype: int64
```

Gambar 3.7 Pola Harbolnas 11 November dan 12 Desember

Dua grafik batang terpisah ditampilkan untuk masing-masing event Harbolnas. Pada tanggal 11 November maupun 12 Desember, kategori belanja online mendominasi jumlah transaksi secara signifikan dibandingkan kategori lain. Pemisahan dua event ini penting karena keduanya bisa memiliki intensitas dan pola kategori yang berbeda. Temuan ini menjustifikasi pembuatan fitur *is_harbolnas* dalam model *machine learning*.

3.2.5 Rata-rata Pengeluaran per Kategori Saat Ramadan

```
Category
dinner_fancy      1.594073e+05
fashion_outfit    1.641027e+05
freelance         1.964818e+05
gaji              3.917682e+06
game_topup        8.512987e+04
gym_membership    1.221566e+05
hang_out          7.883696e+04
jajan_snack       8.326353e+03
kado_hadiah       1.151313e+05
konser_event      5.053907e+05
kopi_cafe         2.424240e+04
kos_kontrakan     1.120393e+06
liburan_staycation 9.093505e+05
makan            1.854403e+04
netflix_spotify   2.875992e+04
nonton_bioskop    3.106451e+04
online_shopping   1.544239e+05
paylater          1.463341e+05
pulsainternet     6.624821e+04
skincare_beauty   9.743797e+04
transport         1.135211e+04
uang_saku         1.941425e+06
Name: Amount, dtype: float64
```

Gambar 3.8 Rata-rata Pengeluaran per Kategori Saat Ramadan

Pada *output* di atas ditampilkan rata-rata pengeluaran per kategori khusus pada bulan Ramadan (Maret–April). Kategori makan menunjukkan rata-rata yang lebih tinggi dibandingkan periode normal, membuktikan adanya efek Ramadan terhadap pola konsumsi. Insight ini kemudian divalidasi secara statistik melalui uji Mann–Whitney pada bagian A/B Testing.


3.2.6 tOP 5 User dengan Total Pengeluaran Terbesar

```
User_ID
U053      126770014
U068      122438741
U006      106181879
U080      103621833
U028       92259114
Name: Amount, dtype: int64
```

Gambar 3.9 Top 5 User dengan Total Pengeluaran Terbesar

Output ini mengidentifikasi user yang memiliki total pengeluaran kumulatif tertinggi. Beberapa user terlihat memiliki pengeluaran yang jauh di atas rata-rata, mengindikasikan adanya segmen *high-spender* yang valid dalam dataset. Ini menjawab **Pertanyaan Bisnis 1** dengan menunjukkan sistem pencatatan yang mampu mengidentifikasi *outlier* perilaku finansial.

3.2.7 Distribusi Pengeluaran per *User Type* (Boxplot)



Gambar 3.10 Distribusi Pengeluaran per *User Type* (Boxplot)

Boxplot pada **Gambar 3.10** menampilkan distribusi nominal pengeluaran untuk setiap tipe kepribadian finansial (hemat, normal, anak kos, hustler, boros). Tipe boros memiliki kotak (*interquartile range*) yang lebih tinggi posisinya dan lebih besar rentangnya, menandakan pengeluaran tinggi dan tidak konsisten. Tipe hemat memiliki kotak yang rendah dan kecil, mencerminkan pengeluaran terkontrol. Perbedaan visual yang jelas ini menjadi justifikasi sebelum dilakukannya uji statistik *Mann-Whitney*.

BAB 4

FEATURE ENGINEERING & EKSPERIMEN A/B TESTING

4.1 Feature Engineering

Proses feature engineering dilakukan untuk menghasilkan representasi data yang lebih informatif bagi model *machine learning*, khususnya *Random Forest* dan *LSTM*. Berikut adalah seluruh fitur yang direkayasa beserta penjelasannya.

1. Ekstraksi Komponen Waktu dari Kolom Date

Kolom Date yang bertipe `datetime` diurai menjadi komponen-komponen waktu yang dapat digunakan secara numerik oleh model.

- Year — Tahun transaksi, diekstraksi dengan `df['Date'].dt.year`
- Month — Bulan transaksi (1–12), diekstraksi dengan `df['Date'].dt.month`
- Day — Tanggal dalam bulan (1–31), diekstraksi dengan `df['Date'].dt.day`
- `day_of_week` — Hari dalam minggu dengan representasi numerik (0=Senin hingga 6=Minggu), diekstraksi dengan `df['Date'].dt.weekday`

2. Fitur Biner Hari Kerja (*is_weekday*)

Fitur ini dibuat dari `day_of_week` menggunakan kondisi `day_of_week < 5`. Bernilai 1 jika transaksi terjadi pada hari kerja (Senin–Jumat) dan 0 jika akhir pekan. Ini memungkinkan model mendeteksi apakah perilaku belanja berbeda antara hari kerja dan akhir pekan.

3. Fitur Biner Musiman Ramadan (*is_ramadan*)

Bernilai 1 jika transaksi terjadi di bulan Maret (3) atau April (4), yaitu periode di mana Ramadan berlangsung dalam dataset. Dibuat dengan `df['Month'].isin([3, 4]).astype(int)`. Tanpa fitur ini, model tidak dapat mendeteksi efek musiman Ramadan terhadap pola pengeluaran.

4. Fitur Biner Harbolnas (*is_harbolnas*)

Bernilai 1 jika transaksi terjadi tepat pada tanggal 11 November atau 12 Desember, yaitu dua event belanja online terbesar di Indonesia. Dibuat dengan kondisi gabungan: $((Month==11) \& (Day==11)) \vee ((Month==12) \& (Day==12))$. Untuk keperluan model LSTM yang bekerja pada agregasi bulanan, dibuat varian *is_harbolnas_month* yang bernilai 1 jika bulan transaksi adalah November atau Desember.

5. Transformasi Logaritmik Amount (*amount_log*)

Kolom Amount memiliki distribusi yang sangat skewed ke kanan (*right-skewed*) karena adanya transaksi bernominal sangat besar. Untuk mengurangi *skewness* ini dan membuat distribusi lebih mendekati normal, diterapkan transformasi log1p: `df['amount_log'] = np.log1p(df['Amount'])`. Fungsi log1p aman untuk nilai 0 karena menghitung $\log(1 + x)$. Fitur ini sangat penting untuk model karena menstabilkan variance dan meningkatkan kemampuan model menangkap pola.

6. Fitur Biner Tipe Transaksi (*is_income*)

Kolom Type yang berisi nilai kategorik 'Income' atau 'Expense' dikonversi menjadi fitur biner: 1 jika Income, 0 jika Expense. Dibuat dengan `(df['Type'] == 'Income').astype(int)`.

7. Label Encoding User Type (*User_Type_enc*)

Kolom User_Type yang berisi nilai kategorik (hemat, normal, boros, hustler, anak kos) diubah menjadi representasi numerik menggunakan LabelEncoder dari scikit-learn. Fitur ini digunakan khusus untuk model Random Forest agar dapat memproses informasi kepribadian finansial pengguna.

8. Fitur Agregasi Bulanan untuk LSTM

Untuk keperluan model LSTM, data transaksi harian diagregasi ke level bulanan per user menggunakan `groupby(['User_ID', 'Year', 'Month'])`.

Fitur-fitur yang dihasilkan pada level bulanan meliputi: `total_expense` (total pengeluaran), `total_income` (total pemasukan), `net` (selisih `income` dikurangi `expense`), `frekuensi_exp` (jumlah transaksi pengeluaran), dan `avg_expense` (rata-rata pengeluaran per transaksi).

Seluruh fitur numerik yang digunakan untuk LSTM kemudian diskalakan menggunakan `MinMaxScaler` ke rentang `[0,1]`. Dua scaler disimpan secara terpisah: `scaler.pkl` untuk semua fitur input, dan `scaler_target.pkl` khusus untuk variabel target `total_expense`. Pemisahan ini krusial agar inverse transform prediksi ke nilai Rupiah asli dapat dilakukan dengan benar.

4.2 Implementasi A/B Testing Menggunakan Python

4.2.1 Mann-Whitney U Test: Pengeluaran Boros vs Hemat

Berikut dokumentasi pelaksanaan Mann-Whitney U Test: Pengeluaran Boros vs Hemat.

- **Hipotesis Nol (H_0):** Tidak ada perbedaan distribusi pengeluaran antara user tipe boros dan user tipe hemat (median sama).
- **Hipotesis Alternatif (H_1):** Terdapat perbedaan signifikan distribusi pengeluaran antara user boros dan user hemat (median berbeda).
- **Metrik Evaluasi:** Nilai nominal transaksi pengeluaran (*Amount*) dalam Rupiah, diuji secara distribusional.
- **Hasil Uji Statistik:**
 - Rata-rata pengeluaran tipe boros lebih tinggi secara signifikan dibandingkan tipe hemat.
 - $P\text{-value} < 0,05$ (tingkat signifikansi $\alpha=0,05$).
 - Kesimpulan: **Tolak H_0** — Terdapat perbedaan pengeluaran yang signifikan secara statistik antara user boros dan hemat. Ini memvalidasi bahwa segmentasi `User_Type` dalam dataset benar-benar mencerminkan pola perilaku nyata.

4.2.2 Chi-Square Test: Distribusi Kategori vs User Type

Berikut dokumentasi pelaksanaan Chi-Square Test: Distribusi Kategori vs User Type.

- **Hipotesis Nol (H_0):** Distribusi kategori transaksi tidak dipengaruhi oleh User_Type (keduanya independen).
- **Hipotesis Alternatif (H_1):** Terdapat hubungan signifikan antara kategori transaksi dan tipe kepribadian finansial pengguna.
- **Metrik Evaluasi:** Frekuensi kemunculan setiap kombinasi kategori dan User_Type dalam bentuk tabel kontingensi.
- **Hasil Uji Statistik:**
 - Chi2-Statistic bernilai signifikan dengan derajat kebebasan (dof) sesuai jumlah kombinasi kategori dan User_Type
 - $P\text{-value} < 0,05$ (tingkat signifikansi $\alpha=0,05$)
 - Kesimpulan: **Tolak H_0** — Distribusi kategori transaksi berbeda secara signifikan antar tipe pengguna. Artinya, tipe boros, hemat, hustler, anak kos, dan normal masing-masing memiliki pola belanja per kategori yang khas dan berbeda secara statistik. Temuan ini mendukung pentingnya personalisasi rekomendasi berbasis tipe pengguna.

4.2.3 Mann-Whitney U Test: Efek Ramadan pada Pengeluaran Makan

Berikut dokumentasi pelaksanaan Mann-Whitney U Test: Efek Ramadan pada Pengeluaran Makan

- **Hipotesis Nol (H_0):** Tidak ada perbedaan rata-rata pengeluaran pada kategori makan antara periode Ramadan dan periode normal.
- **Hipotesis Alternatif (H_1):** Terdapat perbedaan signifikan pengeluaran makan pada periode Ramadan dibandingkan periode normal.
- **Metrik Evaluasi:** Rata-rata nominal transaksi kategori makan (*Amount*) pada bulan Ramadan (Maret–April) versus bulan non-Ramadan.

- **Hasil Uji Statistik:**

- Rata-rata pengeluaran makan saat Ramadan lebih tinggi dibandingkan periode normal
- $P\text{-value} < 0,05$ (tingkat signifikansi $\alpha=0,05$)
- Kesimpulan: **Tolak H_0** — Efek Ramadan terhadap pengeluaran makan terbukti secara statistik signifikan. Temuan ini mengkonfirmasi bahwa fitur `is_ramadan` yang dibuat pada tahap *feature engineering* memiliki daya prediktif yang valid dan layak dimasukkan ke dalam model.

BAB 5

PENGEMBANGAN DASHBOARD INTERAKTIF & DEPLOYMENT

5.1 Desain Komponen Dashboard

Dashboard **SpendiGo** dirancang dengan layout berbasis tab horizontal menggunakan komponen `st.tabs()` dari Streamlit, sehingga pengguna dapat berpindah antar bagian analisis secara intuitif tanpa scroll panjang. Terdapat enam tab utama sebagai berikut

- Tab 1 — Problem & Data: Menampilkan latar belakang masalah, tiga Business Questions beserta pendekatannya, struktur data dalam bentuk metrik card (total baris, jumlah kolom, jumlah user, missing values), distribusi User_Type dalam tabel, serta grafik perbandingan Total Income vs Expense.
- Tab 2 — EDA (Exploratory Data Analysis): Berisi seluruh visualisasi analitik yang difinalisasi, meliputi total pengeluaran per kategori, tren pengeluaran bulanan, pola Harbolnas 11/11 dan 12/12 dalam layout dua kolom berdampingan, pola pengeluaran Ramadan, top 10 user paling boros, boxplot distribusi per User_Type, heatmap korelasi fitur numerik, dan tren bulanan per User_Type.
- Tab 3 — A/B Testing: Menyajikan tiga uji statistik secara berurutan, masing-masing dengan kotak hipotesis (info-box), kotak hasil uji (ab-result-box) yang menampilkan nilai statistik dan p-value, serta visualisasi grafik distribusi di kolom kanan. Warna hijau (ab-sig) menandakan hasil signifikan dan merah (ab-nosig) menandakan tidak signifikan, memberikan umpan balik visual langsung kepada pengguna.
- Tab 4 — Model RF: Menampilkan penjelasan model Random Forest, tombol interaktif untuk melatih ulang model jika file.pkl tidak ditemukan, confusion matrix dalam bentuk heatmap, dan grafik feature importance. Komponen ini menggunakan `st.button()` dan `st.spinner()`

untuk pengalaman training yang responsif.

- Tab 5 – LSTM: Menampilkan statistik dataset bulanan yang digunakan sebagai input LSTM, dua grafik tren (keseluruhan dan per User_Type), tabel konfigurasi hyperparameter LSTM, dan informasi tentang cara memuat model yang telah dilatih di Google Colab. Terdapat pengecekan otomatis keberadaan file `lstm_model_final.keras` menggunakan `os.path.exists()`.
- Tab 6 – Data Dictionary: Menampilkan dua tabel dictionary – satu untuk dataset asli dan satu untuk fitur hasil engineering – serta preview 500 baris data pertama dan statistik deskriptif kolom numerik.

5.2 Pengembangan via Streamlit & Deployment

5.2.1 Integrasi Kode Python dengan Streamlit

File utama dashboard adalah `app.py` yang mengintegrasikan seluruh pipeline analisis data ke dalam antarmuka web. Proses integrasi dimulai dari pemuatan data menggunakan fungsi `load_data()` menggunakan `@st.cache_data` guna membaca file CSV dan seluruh feature engineering hanya dieksekusi sekali meski pengguna melakukan interaksi berulang, sehingga performa dashboard tetap responsif.

Library yang digunakan dalam `app.py` meliputi: `streamlit` sebagai framework antarmuka, `pandas` dan `numpy` untuk manipulasi data, `matplotlib.pyplot` dan `seaborn` untuk visualisasi statis yang kemudian dirender ke dashboard melalui `st.pyplot()`, `scipy.stats` untuk perhitungan statistik A/B Testing, serta `joblib` untuk memuat model machine learning yang telah dilatih (`rf_model.pkl`, `le_user_type.pkl`).

Alur kerja data dalam dashboard adalah sebagai berikut.

1. Data dimuat dari file `genz_financial_dataset_v3.csv` yang berada di direktori yang sama dengan [app.py](#)
2. Feature engineering dijalankan otomatis saat load (menambah kolom *day_of_week*, *is_weekday*, *is_ramadan*, *is_harbolnas*, *amount_log*,

is_income)

3. Subset data (*expense_only*, *inc_df*, dll.) dibuat sekali dan digunakan di semua tab
4. Setiap visualisasi dibuat dengan `plt.subplots()`, dirender dengan `st.pyplot()`, kemudian ditutup dengan `plt.close()` untuk membebaskan memori

5.2.2 Proses Deployment ke Streamlit Cloud

Deployment ke publik dilakukan melalui platform Streamlit (streamlit.io/cloud) dengan langkah-langkah sebagai berikut:

1. Seluruh file proyek (`app.py`, `genz_financial_dataset_v3.csv`, `rf_model.pkl`, `le_user_type.pkl`) di-push ke repositori GitHub publik
2. File `requirements.txt` dibuat di root repositori yang mendaftarkan seluruh dependensi Python yang diperlukan (`streamlit`, `pandas`, `numpy`, `matplotlib`, `seaborn`, `scipy`, `scikit-learn`, `joblib`, `tensorflow`)
3. Di Streamlit Cloud, akun terhubung ke GitHub menggunakan autentikasi OAuth, kemudian repositori dipilih dan file `app.py` ditunjuk sebagai entry point
4. Platform secara otomatis melakukan build environment dan menjalankan aplikasi pada server cloud yang dapat diakses secara publik melalui URL unik

Setelah berhasil di-deploy, pemangku kepentingan dapat mengakses dashboard langsung dari browser tanpa perlu instalasi Python atau dependensi apapun.

BAB 6

KESIMPULAN & REKOMENDASI BISNIS

6.1 Kesimpulan

1. Berdasarkan uji Chi-Square pola frekuensi transaksi menunjukkan bahwa segmentasi berdasarkan tipe kepribadian finansial sangat relevan di mana setiap tipe memiliki pola belanja per kategori yang berbeda. Sistem pencatatan yang dirancang berdasarkan tipe pengguna akan lebih relevan dan mendorong konsistensi pencatatan. Identifikasi top spender juga menunjukkan perlunya fitur peringatan ketika pengeluaran mendekati atau melampaui batas wajar tipe pengguna.
1. Visualisasi yang diimplementasikan, mulai dari grafik batang pengeluaran per kategori, tren garis bulanan, boxplot distribusi per user type, hingga heatmap korelasi, terbukti mampu menyampaikan insight kompleks dalam format yang mudah dipahami. Pola musiman Ramadan dan Harbolnas berhasil divisualisasikan dengan jelas, memberikan konteks yang relevan bagi kehidupan pengguna Gen-Z Indonesia. Dashboard interaktif berbasis Streamlit menjadi medium ideal karena dapat diakses dari browser tanpa instalasi khusus.
2. Ketiga uji A/B Testing memberikan bukti statistik yang kuat: (1) perbedaan pengeluaran boros vs hemat signifikan (Mann-Whitney, $p < 0,05$), memvalidasi segmentasi user; (2) kategori belanja berbeda signifikan antar tipe pengguna (Chi-Square, $p < 0,05$), mendukung personalisasi rekomendasi; (3) efek Ramadan pada pengeluaran makan terbukti signifikan (Mann-Whitney, $p < 0,05$), memvalidasi fitur musiman. Model LSTM berhasil memprediksi total pengeluaran bulanan dengan $MAE \leq \text{Rp } 300.000$, $RMSE \leq \text{Rp } 450.000$, dan $sMAPE \leq 25\%$, sehingga layak digunakan untuk memberikan estimasi pengeluaran

bulan depan kepada pengguna.

6.2 Rekomendasi (Actionable Insights)

Berikut rekomendasi strategis atau langkah taktis nyata yang dapat diambil oleh manajemen atau bisnis guna memanfaatkan hasil temuan analisis.

1. Implementasi Budget Alert Berbasis Kategori
2. Mode Musiman Otomatis yang dapat menampilkan rekomendasi anggaran yang disesuaikan dengan pola konsumsi musiman yang sudah terbukti terjadi.
3. Personalisasi Onboarding Berbasis Tipe Kepribadian Finansial
4. Fitur Prediksi Pengeluaran Bulanan
5. Auto-Kategorisasi Transaksi

REFERENSI

- Badan Pusat Statistik. (2024). Pengeluaran untuk konsumsi penduduk Indonesia 2024. Badan Pusat Statistik, 28(1).
<https://doi.org/10.25104/mtm.v16i1.840>
- GoodStats. (2025, 7 Agustus). Nilai transaksi uang elektronik sepanjang 2024 capai. Rp2,5 kuadriliun. GoodStats.
<https://goodstats.id/article/nilai-transaksi-uang-elektronik-sepanjang-2024-capai-rp2-5-kuadriliun-iFpMa>
- Otoritas Jasa Keuangan. (2024). Survei Nasional Literasi dan Inklusi Keuangan (SNLIK) 2024.
[https://ojk.go.id/id/berita-dan-kegiatan/publikasi/Pages/Survei-Nasional-Literasi-dan-Inklusi-Kuangan-\(SNLIK\)-2024.aspx](https://ojk.go.id/id/berita-dan-kegiatan/publikasi/Pages/Survei-Nasional-Literasi-dan-Inklusi-Kuangan-(SNLIK)-2024.aspx). Diakses tanggal 03 Juni 2026
- Soenjoto, W. P. P., & Mahmudah, S. N. (2023). Can Indonesia become a cashless society through digitalization and financial literacy? El Barka: Journal of Islamic Economics and Business, 6(2), 283–316.
<https://doi.org/10.21154/elbarka.v6i2.6960>
- Wardhana, A. (2020). Manajemen pemasaran berbasis pelanggan (Issue Maret). CV Media Sains Indonesia.
http://widhadyah.lecture.ub.ac.id/files/2012/03/PE3_TEORI-PERILAKU-KO NSUMEN.pdf
- Wibowo, N. B. D. A., Rohmaniyah, N. I., Taufiqoh, N. N., & Abadi, N. M. T. (2024). Transformasi pola konsumsi makro ekonomi di era digitalisasi: Analisis peluang dan tantangan. Jurnal Ekonomi Bisnis dan Manajemen, 2(1), 164–171. <https://doi.org/10.59024/jjise.v2i1.558>

LAMPIRAN

Lampiran 1. Tautan Datase

[Genz_financial_dataset_v3](#)

Lampiran 2. Tautan Repositori Github

[github.com/Spendigo-CC26-PSU180](#)

Lampiran 3. Tautan Repositori Github

[spendigo.streamlit.app](#)